AnnotationHub

AnnotationHub包提供了一个访问Bioconductor AnnotationHub网站资源的客户端,该网站存放来自标准机构的基因组资源文件,例如UCSC, Ensembl等的vcf,bed,wig文件资源。

library(AnnotationHub)

ah <- AnnotationHub()</pre>

使用以下函数查询AnnotationHub的信息(x为AnnotationHub objects)

hubCache(x):返回本地AnnotationHub cache的系统存放位置

removeCache(x): 删除本地AnnotationHub数据以及相关资源

hubUrl(x): 返回在线hub的url

names(x): 返回hub记录的名称,AnnotationHub unique identifiers, AH12345

fileName(x): 返回本地cache的hub记录的文件路径

mcols(x): 返回记录的metadata列信息

dbfile(x): 返回SQLite 数据的全路径

使用以下函数访问AnnotationHub object

query(x, pattern, ignore.case=T, pattern.op='&'): 返回匹配pattern的AnnotationHub 对象的子 集

使用 '[[' 下载records, 首次使用时,对应的文件和其他hub资源回从网上下载到local cache。随后就可以快速使用这些local cache文件。假如想再次下载,而不是用cache文件,则需要加上参数'force=TRUE'。

res <- ah[["AH67442"]]

subset(x, subset): 返回匹配subset表达式的子集

display(x): 网页展示hub记录

keys: 返回包含在AnnotationDb对象中数据的关键字,搭配select使用

columns: 显示AnnotationDb对象所能返回的数据种类

keytypes: 显示可以供select, keys和keytype能选择的关键字类型

loadDb: 装载离线下载的annotation package

head(keys(orgdb, keytype="SYMBOL"))

select(x, keys, columns, keytype, ...):根据keys, columns, keytype等参数以数据框的格式返回AnnotationDb对象所含内容, 而maplds返回向量

trial.sample <- sample(keys(orgdb,keytype="ENTREZID"))</pre>

```
select(orgdb,keys=trial.sample,column=("SYMBOL"),keytype="ENTREZID")
mapIds(orgdb,keys=trial.sample,column=("SYMBOL"),keytype="ENTREZID")
ah_kpc <- query(ah, c("klebsiella"))
ah_kpc[1]
ah_kpc$sourceurl
ah_kpc$description
ah_kpc$title</pre>
```

mapIds(x, keys, columns, keytype,...),同select用法,常用于返回字符向量

● 针对无法下载的ah,例如klebsiella_res <- ah[["AH67442"]],可选择百度网盘下载后,根据错误 提示,将文件直接cp到提示文件及名称

cp org.Klebsiella_pneumoniae.eg.sqlite /Users/carlos/.AnnotationHub/74188

```
> klebsiella_res <- ah[["AH67442"]]
downloading 0 resources
loading from cache
    '/Users/carlos//.AnnotationHub/74188'
Loading required package: AnnotationDbi
Loading required package: stats4
Loading required package: Biobase
Welcome to Bioconductor</pre>
Vignettes contain introductory material; view with
```

```
> head(select(klebsiella_res,keys=keys(klebsiella_res),keytype="ENTREZID",columns=c("ENTREZID","GENE
NAME","GID","G0","ONTOLOGY","SYMBOL"))
'select()' returned 1:many mapping between keys and columns
                    GENENAME
                                 GID
                                               GO ONTOLOGY SYMBOL
  1238784 klebicin B lysis 1238784 G0:0019867
                                                                kb1
  1238784 klebicin B lysis 1238784 GO:0019835
                                                         BP
                                                                kb1
  1238784 klebicin B lysis 1238784 GO:0009405
                                                         ΒP
                                                                kbl
                          kbi 1238785 G0:0015643
  1238785
                                                         MF
                                                                kbi
  1238785
                          kbi 1238785 GO:0030153
                                                          BP
                                                                kbi
   1238786
                  klebicin B 1238786 GO:0004519
                                                         MF
                                                                kba
```

GenomicFeatures

GenomicFeatures包使用TxDb对象存储转录组数据,包括UTRs,CDSs,外显子信息等。所有TxDb对象都以SQLite database备份,包含基因组的位置,pre-processed mRNA转录本,外显子,蛋白编码序列之间关系以及它们相关基因识别符。

```
loadDb(): 直接从合适的.sqlite数据文件读取对象
```

```
txdb <- loadDb(samplefile.sqlite)</pre>
```

或者

library(TxDb.Hsapiens.UCSC.hg19.knownGene)

```
txdb <- TxDb.Hsapiens.UCSC.hg19.knownGene
seglevels(txdb): 查看染色体水平
TxDb对象inherit from AnnotationDb对象(Just as the ChipDb and OrgDb objects),可以使用
columns, keytypes, keys,和select函数操作TxDb对象。
transcripts(txdb): 返回所包含转录本位置区间信息
exons(txdb): 返回对应外显子区间信息
transcriptsBy(txdb, by="gene"): 查看根据genes分组的转录本信息
exonsBy(txdb, by="tx"): 查看根据转录本分组的基因信息
intronsByTranscript(txdb), fiveUTRsByTranscript(txdb), threeUTRsByTranscript(txdb)同上功能
提取序列信息
tx_seq <- extractTranscriptSeqs(Hsapiens, TxDb.Hsapiens.UCSC.hg19.knownGene,</pre>
use.names=T)
转录序列成蛋白序列
translate(extractTranscriptSeqs(Hsapiens,txdb))
创建新的TxDb对象
GenomicFeatures包可使用从UCSC Genome Bioinformatics或BioMart下载的数据创建TxDb对象
supportedUCSCtables(genom="hg19")
查看UCSC基因组hg19所包含的tables信息
txdb from hg19 <- makeTxDbFromUCSC(genome="hg19",tablename="knownGene"</pre>
使用makeTxDbFromBiomar来从BioMart获得指定mart和data set的数据
txdb from biomart <- makeTxDbFromBiomart()</pre>
makeTxDbFromBiomart(biomart="ENSEMBL_MART_ENSEMBL",dataset="hsapiens_gene_ensembl
", ...)
使用makeTxDbFromEnsembl,
makeTxDbFromEnsembl(organism="Homo sapiens",release=NA, ...)
同样可以使用makeTxDbFromGFF, makeTxDbFromGRanges来创建TxDb对象。
保存和载入TxDb对象,由于TxDb对象以SQLite数据备份,因此保存也为该格式
一旦创建了TxDb对象,可以保存本地,避免反复创建
saveDb(txdb, file="fileName.sqlite")
txdb <- loadDb("fileName.sqlite")</pre>
```

BSgenome & VariantAnnotation

```
BSgenome包存储基因组信息及snp信息
available.genomes(): 查看当前基因组信息
选择加载hg19
library(BSgenome.Hsapiens.UCSC.hg19)
定位genes内以及周围的变异
locateVariants(query, subject, region, ...)
query: 包含变异的IntegerRanges, Granges 或 VCF对象
subject: 用于注释的TxDb或'GRangesList'对象
region: 8种变异类型中的一个'CodingVariants', 'IntronVariants', 'FiveUTRVariants',
'ThreeUTRVariants', 'IntergenicVariants', 'SpliceSiteVariants', 'PromoterVariants', 'AllVariants'.
library(VariantAnnotation)
f1 <- system.file("extdata", "chr22.vcf.gz", package="VariantAnnotation")</pre>
vcf <- readVcf(f1, "hg19")</pre>
library(TxDb.Hsapiens.UCSC.hg19.knownGene)
txdb <- TxDb.Hsapiens.UCSC.hg19.knownGene</pre>
seqlevels(vcf) <- "chr22"</pre>
rd <- rowRanges(vcf)</pre>
loc <- locateVariants(rd, txdb, CodingVariants())</pre>
预测氨基酸密码子改变
针对非同义变异, predictCoding计算氨基酸密码子的改变,只有来自subject中coding区域的query序列
范围的改变才会预测,同时参考序列来自于BSgenome或有seqSource指定的fasta文件
IntergenicVariants(upstream = 1e+06L, downstream = 1e+06L,idType=c("gene", "tx"))
predictCoding(query, subject, seqSource, varAllele, ..., ignore.strand=FALSE)
query: GRanges或vcf文件,如果是GRanges文件,就需要指定varAllele参数,如果是vcf文件,那么
alternate alleles就从alt(vcf)中获得
subject: 用于注释的TxDb文件
seqSource: 一个 BSgenom instance或FaFile用于序列的提取
varAllel: 包含变异等位基因的DNAStringSet
library(BSgenome.Hsapiens.UCSC.hg19)
conding <- predictCoding(vcf, txdb, seqSource=Hsapiens)</pre>
```

或

```
rd <- rowRanges(vcf)

altallele <- alte(vcf)

eltROWS <- elementNROWS(altallele)

rd_exp <- rep(rd, eleROWS)

predictCoding(rd_exp , txdb, Hsapiens)

使用filterVcf函数过滤变异,略!!!
```

biomaRt

library(biomaRt)

第一步检查BioMart网络服务

useMart()函数指定需要连接的BioMart数据库,名称由listMarts()返回

```
ensembl=useMart("ensembl")
```

BioMart数据库能包含多个数据集,对于Ensembl,每个物种都是一个不同的数据集,使用listDatabasets()展示可用的数据集

datasets <- listDatasets(ensembl)</pre>

```
> head(datasets)
                       dataset
                                                          description
1 abrachyrhynchus_gene_ensembl Pink-footed goose genes (ASM259213v1)
      acalliptera_gene_ensembl
                                    Eastern happy genes (fAstCal1.2)
   acarolinensis_gene_ensembl
                                      Anole lizard genes (AnoCar2.0)
    acitrinellus_gene_ensembl
                                      Midas cichlid genes (Midas_v5)
5
         ahaastii_gene_ensembl
                                  Great spotted kiwi genes (aptHaa1)
     amelanoleuca_gene_ensembl
                                                Panda genes (ailMel1)
     version
 ASM259213v1
  fAstCal1.2
3
    AnoCar2.0
    Midas_v5
      aptHaa1
      ailMel1
```

使用useDataset选择数据集,更新Mart对象

```
ensembl = useDataset("hsapiens gene ensembl", mart=ensembl)
```

或者直接使用useMart选择更新

```
ensembl = useMart("ensembl", dataset="hsapines_gene_ensembl")
```

构建biomaRt查询

getBM()函数拥有三个参数: filters, atrributes和values, 是biomaRt的主要函数

filters定义了query的限制范围:

filters <- listFilters(ensembl)</pre>

```
> filters[1:5,]
                                 description
             name
 chromosome_name Chromosome/scaffold name
            start
                                       Start
3
              end
                                         End
                                  Band Start
       band_start
         band_end
                                    Band End
```

attributes定义了query想要查询的范围:

attributes <- listAttributes(ensembl)</pre>

```
attributes[1:5,]
                                               description
                                                                   page
                         name
                                            Gene stable ID feature_page
              ensembl_gene_id
      ensembl_gene_id_version
                                    Gene stable ID version feature_page
        ensembl_transcript_id
                                     Transcript stable ID feature_page
ensembl_transcript_id_version Transcript stable ID version feature_page
           ensembl_peptide_id
                                         Protein stable ID feature_page
```

getBM()共含有4个主要参数:

affy_hg_u133_plus_2 entrezgene 202763_at

209310_s_at

207500_at

- attributes, 想要获得的属性向量, 等同于query的输出
- filters,需要过滤掉的值的向量,对应values信息,且要一一对应
- values, filters的值的向量,可以为多重filters,为list

836

837

838

● mart, Mart类别对象,使用useMart()函数构建

另外一些函数如getGenes()和getSequence()函数同样可以实现getBM()功能,对应指定的属性和过滤条 件。

```
getBM(attributes, filters = "", values = "", mart, curl = NULL, checkFilters =
TRUE, verbose = FALSE, uniqueRows = TRUE, bmHeader = FALSE, quote = "\"")
例如,在affymetirx中查询对应EntrezGene id
affyids <- c("202763_at", "209310_s_at", "207500_at")
getBM(attributes=c("affy hg u133 plus 2", entrezgene",),
filters="taffy_hg_u133_plus_2", values=affyids, mart=ensembl)
 getBM(attributes=c("affy_hg_u133_plus_2","entrezgene"),filters="affy_hg_u133_plus_2",values=affyid
s,mart=ensembl)
```

针对listDatasets(), listAttributes(), listFilters()返回的长的结果内容,可以使用searchDatasets(), searchAttributes(), searchFilters()对应搜索匹配指定条目的结果, pattern为正则表达式:

searchDatasets(mart=ensembl, pattern="hsapiens")

searchAttributes(mart=ensembl, pattern="hgnc")

使用正则表达实现具体搜索

searchFilters(mart=ensembl, pattern="ensembl.*id")

```
> searchFilters(mart=ensembl,pattern="ensembl.*id")
54
                 ensembl_gene_id
         ensembl_gene_id_version
55
56
           ensembl_transcript_id
57 ensembl_transcript_id_version
58
              ensembl_peptide_id
59
      ensembl_peptide_id_version
60
                 ensembl_exon_id
                                                       description
54
                         Gene stable ID(s) [e.g. ENSG00000000003]
55
         Gene stable ID(s) with version [e.g. ENSG00000000003.14]
                   Transcript stable ID(s) [e.g. ENST00000000233]
56
57 Transcript stable ID(s) with version [e.g. ENST00000000233.10]
58
                      Protein stable ID(s) [e.g. ENSP00000000233]
59
       Protein stable ID(s) with version [e.g. ENSP00000000233.5]
                                 Exon ID(s) [e.g. ENSE00000327880]
60
```

然后根据提示,具体搜索:

```
> getBM(attributes=c("entrezgene"),filters="ensembl_transcript_id_version",
+ values=c("ENST00000577249.1"),mart=ensembl)
    entrezgene
1 990
> getBM(attributes=c("ensembl_transcript_id_version","entrezgene"),filters="ensembl_transcript_id_version",values=c("ENST00000577249.1"),mart=ensembl)
    ensembl_transcript_id_version entrezgene
1 ENST00000577249.1 990
```

示例

1. 使用HUGO和对应基因的染色体位置注释affymatrix identifiers

```
affyids <- c("202763 at", "209310 s at", "207500 at")
```

```
getBM(attributes=c("affy hg u133 plus 2", "hgnc symbol","chromosome name",
"start_position", "end_position", "band"), filters="affy_hg_u133_plus_2"),
values=affyids, mart=ensembl)
 getBM(attributes=c("affy_hg_u133_plus_2","hgnc_symbol","chromosome_name","start_position","end_pos
ition","band"),filters="affy_hg_u133_plus_2",values=affyids,mart=ensembl)
 affy_hg_u133_plus_2 hgnc_symbol chromosome_name start_position end_position
          202763_at
                       CASP3
                                        4
                                               184627696
                                                          184649509
        209310_s_at
                        CASP4
                                               104942866
                                                          104969366
                        CASP5
          207500_at
                                        11
                                               104994235
                                                          105023168
  band
 q35.1
 q22.3
 q22.3
 2. 使用GO注释EntrezGene ids
entrez <- c("673", "837")
goids <- getBM(attributes=c("entrezgene", "go_id"), filters="entrezgene",</pre>
values=entrez, mart=ensembl)
   head(goids)
                           go_id
   entrezgene
              673 GO:0005524
2
              673 GO:0007165
3
              673 GO:0006468
              673 GO:0035556
4
5
              673 GO:0004672
6
              673 GO:0046872
 3. 查询位于17/20/Y染色体上属于指定GO条目的HUGO gene名称
go <- ("GO:0051330", "GO:0000080", "GO:0000114", "GO:0000082")
chrom <- c(17,20,"Y")
getBM(attributes="hgnc symbol", filters=c("go", "chromosome name"),
values=list(go, chrom), mart=ensembl)
  getBM(attributes = "hgnc_symbol",filters=c("go","chromosome_name"),values=list(go,chrom),mart=ense
mbl)
 hgnc_symbol
     RPS6KB1
2
        RPA1
        CDK3
        CDC6
       MCM8
       CRLF3
```

或者,去除染色体的限制,增加attributes内容输出,filter和values——对应!

4. 使用INTERPRO蛋白结构域注释refseq ids

```
refseqids <- c("NM_005359", "NM_000546")
ipro <- getBM(attributes=c("refseq_mrna", "interpro",
"interpro_description"),filters="refseq_mrna", values=refseqids, mart=ensembl)</pre>
```

```
refseq_mrna interpro
 NM_000546 IPR002117
 NM_000546 IPR008967
 NM_000546 IPR010991
 NM_000546 IPR011615
 NM_000546 IPR012346
 NM_000546 IPR013872
 NM_000546 IPR036674
 NM_005359 IPR001132
 NM_005359 IPR003619
 NM_005359 IPR008984
 NM_005359 IPR013019
 NM_005359 IPR013790
 NM_005359 IPR017855
 NM_005359 IPR036578
                                              interpro_description
                                     p53 tumour suppressor family
                       p53-like transcription factor, DNA-binding
                                      p53, tetramerisation domain
```

5. 查询染色体固定区间的gene信息

```
getBM(attributes = c('affy_hg_u133_plus_2', 'ensembl_gene_id')
,
    filters = c('chromosome_name', 'start', 'end'),
    values = list(16,1100000,1250000),
    mart = ensembl)
```

filters信息要和values信息——对应

6. 查询'MAP kinase activity' 相关GO term的所有HUGO基因名称

```
getBM(attributes = c('entrezgene', 'hgnc_symbol'),
    filters = 'go',
    values = 'G0:0004707',
    mart = ensembl)
```

7. 针对指定EntrezGene ids查询启动子上游100bp序列

可直接使用getSequence()函数获取序列信息

```
getSequence(chromosome, start, end, id, type, seqType,upstream, downstream, mart,
verbose = FALSE)
```

8. 查询位于3号染色体指定位置的所有5' utr序列

9. 查询指定entrezgene的蛋白序列

首先使用不同的BioMart数据库

```
snpmart <- useMart(biomart="ENSEMBL_MART_SNP", dataset="hsapiens_snp")</pre>
```

```
getBM(attributes=c("refsnp_id", "allele", "chrom_start", "chrom_strand"),
+ filters=c("chr_name","start","end"),
+ values=list(8,148350,148612),
+ mart=snpmart)
     refsnp_id allele chrom_start chrom_strand
  rs1450830176
                   G/C
                            148350
                            148352
  rs1360310185
                   C/T
                                               1
  rs1434776028
                   A/T
                            148353
  rs1413161474
                   C/T
                            148356
  rs1410590268
                   A/G
                            148365
  rs1193735780 T/A/C
                            148368
```

AnnotationForge

构建organism package可直接使用函数makeOrgPackageFromNCBI()或makeOrgPackage()。若 package可使用NCBI Taxonomy ID通过NCBI构建,该命令根据tax_id从NCBI搜索相应gene records,因此选择正确的NCBI taxonomy ID很重要。例如,构建zebrafinch organism package:

若不能从NCBI处获得所有构建信息,可从其他资源使用makeOrgPackage()函数构建,该函数不依赖 NCBI构建。该函数使用data.frame的field name构建为相应的数据库信息,同时可通过columns()和 keytypes()查看所构建数据库。对所添加数据种类没有限制,但是data.frame的第一列对应gene ID,命 名为"GID"。

当data.frame包含GO information时,使用goTable方法指明。若使用该选项,makeOrgPackage()将 1)remove IDs that are too new,2) create a second table to also represent the GOALL, EVIDENCEALL, ONTOLOGYALL fields for the select method。此种情况(使用goTable),需准守严格规则,该data.frame仅需包含3列,对应为gene id, GO id 和 evidence codes,对应名称为"GID", "GO"和"EVIDENCE":

```
head(fG0)
                    GO EVIDENCE
        GID
1 100190152 GO:0008152
                            IEA
2 100190152 GO:0016310
                            IEA
3 100190152 GO:0006222
                            IEA
4 100190152 GO:0015937
                            IEA
5 100190152 GO:0000166
                            IEA
6 100190152 GO:0005524
                            IEA
> head(fSym)
     GID SYMBOL
                                                                 GENENAME
1 751582 SNCA synuclein, alpha (non A4 component of amyloid precursor)
2 751583 NCALD
                                                       neurocalcin delta
3 751584
         BDNF
                                       brain-derived neurotrophic factor
4 751585 CREB1
                               cAMP responsive element binding protein 1
5 751586 MTNR1A
                                                   melatonin receptor 1A
                                                   melatonin receptor 1B
6 751588 MTNR1B
> head(fChr)
     GID CHROMOSOME
1 751582
2 751583
                  2
3 751584
                  5
4 751585
5 751586
                  4
6 751588
```

以上三个data.frame先分别删除没有信息列

```
makeOrgPackage(go=fGO,gene_info=fSym,chromosome=fChr,
                   version="0.1",
2
3
                   maintainer = "carlos <carlos@google.com>",
4
                   author="carlos <carlos@google.com>",
5
                   outputDir = ".",
6
                   tax_id="58729",
7
                   genus="Taeniopygia",
8
                   species = "guttata",
9
                   goTable = "go", verbose=T)
   install.packages("./org.Tguttata.eg.db",repos=NULL,type="source")
```

本地安装package需指明type为"source"

其中go=fGO/gene_info=fSym/chromsoem=fChr 满足: 1)数据框, 2)第一列名为"GID", 3)不含 rownames信息; 4)各data.frame的列名称将成为columns()和keytypes()信息,供select()函数使用。